

RNCP36739 — Expert en Ingénierie de Données

Conclusion & références

Bilan du parcours et bibliographie consolidée

Master 2 Data Engineering & IA — EFREI Paris

Julien TREMONT-RAIMI • Antoine VANDEPLANQUE • Promotion 2024–2026

1 Conclusion

1.1 Fil conducteur — du stockage à la valeur métier

Ce rapport a présenté cinq projets. Ensemble, ils couvrent tout le cycle de vie de la donnée, du stockage brut jusqu'à la décision [1]. Chaque couche — Bronze, Silver, Gold — transforme un peu plus la donnée. Chaque outil — Spark, DynamoDB, Lambda, scikit-learn — répond à un besoin précis.

Ces choix ne sont pas arbitraires. Avant chaque décision technique, nous nous sommes posé les bonnes questions : quel volume ? quelle latence ? quel coût ? Puis nous avons comparé les options. Savoir justifier un choix, et pas seulement le citer, est au centre du métier.

1.2 Progression observée sur deux années

Notre niveau a nettement évolué en deux ans. Au début, nos pipelines étaient simples et séquentiels. Aujourd'hui, nous concevons des architectures distribuées en plusieurs couches. Côté cloud, nous sommes passés de simples appels boto3 à une vraie architecture serverless, pensée pour le coût et la sécurité. En machine learning, nous ne testons plus un seul modèle mais un benchmark complet, avec interprétabilité et mise en service. Enfin, la chaîne CI/CD montre une vraie maturité côté DevOps.

1.3 Prise de recul — limites et axes d'amélioration

Nos projets ont aussi des limites, et nous les assumons. Le monitoring reste incomplet : pas encore de suivi temps réel de la latence ni des erreurs, même si CloudWatch et la Spark UI posent les bases. Nous n'avons pas non plus testé nos pipelines sur des volumes beaucoup plus grands. Enfin, en production réelle, il faudrait détecter la dérive des données et réentraîner les modèles automatiquement. Ce sont nos prochaines pistes.

1.4 Ouverture

Ce rapport est la base de notre dossier de certification. La soutenance sera l'occasion d'approfondir les choix clés : le GSI DynamoDB, l'AQE dans Spark, le benchmark des modèles. Le code, les modèles, les tableaux de bord et les pipelines CI/CD réalisés pendant ces deux ans sont la preuve concrète de notre travail. Ils montrent que les cinq blocs sont acquis.

Références

- [1] France Compétences. *Fiche RNCP36739 — Expert en ingénierie de données*. Disponible sur : <https://www.francecompetences.fr/recherche/rncp/36739/>.
- [2] Zaharia M., Xin R. S., Wendell P. *et al.* *Apache Spark : A Unified Engine for Big Data Processing*. *Communications of the ACM*, vol. 59, n°11, pp. 56–65, 2016. DOI : <https://doi.org/10.1145/2832718>.

- [//doi.org/10.1145/2934664](https://doi.org/10.1145/2934664)
- [3] Apache Software Foundation. *Structured Streaming Programming Guide — Apache Spark*. Documentation officielle, version 3.x. Disponible sur : <https://spark.apache.org/docs/latest/structured-streaming-programming-guide.html>.
 - [4] Apache Software Foundation. *Apache Parquet — Columnar Storage Format*. Disponible sur : <https://parquet.apache.org/>.
 - [5] Apache Software Foundation. *Apache Hive — Data Warehouse Software*. Disponible sur : <https://hive.apache.org/>.
 - [6] Oracle Corporation. *MySQL 8.0 Reference Manual*. Disponible sur : <https://dev.mysql.com/doc/refman/8.0/en/>.
 - [7] Django Software Foundation. *Django REST Framework — Web APIs for Django*. Disponible sur : <https://www.django-rest-framework.org/>.
 - [8] Amazon Web Services. *Amazon S3 — Object Storage*. Documentation officielle AWS. Disponible sur : <https://docs.aws.amazon.com/s3/>.
 - [9] DeCandia G., Hastorun D., Jampani M. et al. *Dynamo : Amazon's Highly Available Key-value Store*. *ACM SIGOPS Operating Systems Review*, vol. 41, n°6, pp. 205–220, 2007. DOI : <https://doi.org/10.1145/1323293.1294281>
 - [10] Amazon Web Services. *AWS Lambda — Serverless Compute*. Documentation officielle AWS. Disponible sur : <https://docs.aws.amazon.com/lambda/>.
 - [11] Amazon Web Services. *Amazon API Gateway*. Documentation officielle AWS. Disponible sur : <https://docs.aws.amazon.com/apigateway/>.
 - [12] Amazon Web Services. *Boto3 — AWS SDK for Python*. Documentation officielle. Disponible sur : <https://boto3.amazonaws.com/v1/documentation/api/latest/index.html>.
 - [13] Pedregosa F., Varoquaux G., Gramfort A. et al. *Scikit-learn : Machine Learning in Python*. *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.
 - [14] McKinney W. *Data Structures for Statistical Computing in Python*. *Proceedings of the 9th Python in Science Conference*, pp. 56–61, 2010. DOI : <https://doi.org/10.25080/Majora-92bf1922-00a>
 - [15] Ramírez S. *FastAPI — Modern, fast web framework for building APIs with Python*. Documentation officielle. Disponible sur : <https://fastapi.tiangolo.com/>.
 - [16] Streamlit Inc. *Streamlit — A faster way to build and share data apps*. Documentation officielle. Disponible sur : <https://docs.streamlit.io/>.
 - [17] GitHub, Inc. *GitHub Actions Documentation*. Disponible sur : <https://docs.github.com/actions>.
 - [18] Docker, Inc. *Docker Documentation*. Disponible sur : <https://docs.docker.com/>.
 - [19] Open-Meteo. *Open-Meteo — Free Weather API*. Disponible sur : <https://open-meteo.com/>.