

RNCP36739 — Expert en Ingénierie de Données

Rapport de certification

Introduction, présentation de l'entreprise
et synthèse des blocs de compétences

Master 2 Data Engineering & IA — EFREI Paris

Julien TREMONT-RAIMI • Antoine VANDEPLANQUE • Promotion 2024–2026

Remerciements

Je tiens à exprimer mes remerciements les plus sincères au intervenants et professeurs. La richesse de leurs enseignements ont grandement enrichi mes connaissances et affûté mes compétences ; leur encadrement, leur conseils, prodigués tout au long de cette formation, ont été essentiels de ma progression.

Enfin, je voudrais exprimer ma profonde gratitude envers toutes les personnes de Geismar pour le cadre d'apprentissage qu'elles m'ont offert. Cet environnement a joué un rôle déterminant dans mon développement professionnel en me permettant d'acquérir de nouvelles compétences. Je tiens à souligner combien les opportunités d'expérimentation qui m'ont été offertes ont été d'une valeur inestimable.

À tous, merci pour votre contribution essentielle à la concrétisation de ce projet.

1 Introduction

La donnée s'est imposée comme l'un des actifs stratégiques majeurs des organisations contemporaines. Derrière chaque tableau de bord, chaque modèle prédictif et chaque service numérique se trouve une chaîne d'ingénierie qui transforme des flux bruts, massifs et hétérogènes en information fiable, exploitable et créatrice de valeur. C'est précisément ce métier de **data engineer** que ce rapport entend illustrer : concevoir, construire et industrialiser cette chaîne, de la source jusqu'à la décision.

Ce document constitue le dossier écrit de certification professionnelle **RNCP36739** « Expert en Ingénierie de Données », produit dans le cadre du Mastère Data Engineering & IA d'EFREI Paris (promotion 2024–2026). Il vise à démontrer l'acquisition des cinq blocs de compétences du référentiel [1] à travers des **réalisations concrètes** plutôt que des connaissances théoriques isolées.

La démonstration s'appuie sur cinq projets complémentaires, chacun choisi pour illustrer au mieux un pan du métier : **Jobtech**, plateforme d'agrégation de données d'emploi tech à partir de six sources hétérogènes ; Le **project cloud**, plateforme serverless AWS de mobilité urbaine en temps réel ; Le **projet spark**, pipeline Big Data distribué sur données aéronautiques ; **fizzbuzz Efrei**, chaîne d'intégration et de déploiement continus conteneurisée ; et le **projet datas cience project**, système de maintenance prédictive industrielle par apprentissage automatique. Le tableau ci-dessous récapitule leur rattachement aux blocs du référentiel.

Projet	Domaine	Blocs couverts
Jobtech	Agrégation de données d'emploi tech européen	Bloc 1 (principal), Bloc 5
project_cloud	Plateforme temps réel de mobilité (AWS)	Bloc 1 (NoSQL), Bloc 3, Bloc 5
projet_spark	Pipeline Big Data aéronautique US	Bloc 2 (principal)
fizzbuzz-Efrei	Chaîne CI/CD et conteneurisation	Bloc 2 (DevOps)
data_science_project	Maintenance prédictive industrielle (ML)	Bloc 4 (principal)

Chaque bloc suit une structure identique — compétences visées, contexte et enjeux, architecture, réalisations techniques commentées, axes d'amélioration et synthèse reliée au référentiel — de sorte que chaque partie soit autonome et directement évaluable. Le rapport est précédé d'une présentation de l'entreprise d'alternance, puis d'une synthèse de la couverture des cinq blocs de compétences.

2 Présentation d'entreprise

2.1 L'entreprise : Geismar

Fondée en 1924 à Colmar par Lucien Geismar, la société conçoit, fabrique et vend dans le monde entier des outils et des machines destinés à la pose et à l'entretien des voies ferrées et des caténaires.

Le siège social est aujourd'hui situé à la Défense. L'entreprise compte 750 salariés, dont 420 en France, et possède cinq usines : trois en France (Colmar, Marseille et Saint-Didier-de-la-Tour) et deux à l'étranger (Italie et États-Unis).

Geismar est présent commercialement dans de nombreux pays, notamment en France, au Royaume-Uni, aux États-Unis, au Brésil, en Allemagne, en Italie, en Espagne, au Canada et en Afrique du Sud. Le groupe réalise environ 85 % de son chiffre d'affaires à l'étranger.

2.2 Le poste : Alternant Data Engineer

2.2.1 Contexte

Geismar utilise différents systèmes ERP selon les filiales : M3, Business Central, ou encore des bases Access héritées de systèmes plus anciens. Cette diversité crée un besoin de centralisation et d'harmonisation des données à l'échelle du groupe.

2.2.2 Missions

Mon rôle consiste à développer des pipelines de données en Python pour extraire, transformer et charger les données issues des différents ERP. Ces données sont ensuite structurées via une solution de big data selon une architecture Bronze-Silver-Gold, qui permet de passer progressivement des données brutes à des données exploitables pour le reporting.

Je travaille principalement sur les données financières, la gestion des stocks, le suivi des commandes et le reporting opérationnel des différentes filiales. Une partie importante de mon travail consiste également à migrer les données vers Snowflake.

2.2.3 Environnement technique

J'utilise principalement Python et SQL pour le développement. Les données sont stockées sur SQL Server et Snowflake. L'infrastructure cloud repose sur Microsoft Azure, notamment Blob Storage pour le stockage et Azure DevOps pour le versionning et les pipelines. Côté restitution, les données alimentent des rapports Power BI.

3 Synthèse des blocs de compétences RNCP36739

La certification « Expert en Ingénierie de Données » s'articule autour de cinq blocs de compétences fondamentaux. Ils couvrent l'intégralité du cycle de vie de la donnée dans un environnement Big Data : de la conception d'architectures de stockage et de traitement des données massives (Blocs 1 et 2) à leur déploiement optimisé sur le cloud (Bloc 3), en passant par l'application des méthodes d'intelligence artificielle (Bloc 4) et l'élaboration de stratégies de gouvernance des données (Bloc 5).

Bloc	Intitulé	Compétences clés
RNCP36739 Bloc 1	Concevoir et développer une architecture de stockage de données	Bases de données relationnelles et non-relationnelles, construction de Datalake, création d'API d'accès aux données.
RNCP36739 Bloc 2	Concevoir, développer et déployer une solution de traitement des données massives	Architectures distribuées, systèmes de streaming, optimisation des pipelines, automatisation CI/CD (conteneurisation, ordonnancement).
RNCP36739 Bloc 3	Implémenter et optimiser des solutions de stockage et de traitement de données sur le cloud	Solutions cloud (stockage, pipelines), sécurisation (chiffrement, IAM, conformité), optimisation des performances et des coûts.
RNCP36739 Bloc 4	Implémenter des méthodes d'intelligence artificielle pour modéliser et prédire de nouveaux comportements	Extraction et préparation des données, tableaux de bord interactifs, modèles prédictifs supervisés, évaluation des performances.
RNCP36739 Bloc 5	Concevoir une stratégie de management et de gouvernance de données	Gouvernance (politiques, rôles), conformité (régulations, vie privée), audit qualité, stratégie de sécurité et d'accès aux données.

Références

- [1] France Compétences. *Fiche RNCP36739 — Expert en ingénierie de données*. Disponible sur : <https://www.francecompetences.fr/recherche/rncp/36739/>.