



EFREI Paris

Master 2 Data Engineering & IA

RNCP36739 – Expert en Ingénierie de Données

Rapport écrit de certification

Epreuve certifiante – Evaluation des compétences

Titre du rapport à compléter

Auteur : Tonio
Promotion : 2025–2026
Encadrant : A compléter
Entreprise : A compléter

15 juin 2026

Table des matières

Remerciements	1
1 Introduction et note explicative : objectifs	1
1.1 Attendus du rapport	1
1.2 Conseil de rédaction	1
2 Presentation rapide de l'entreprise et des missions	1
2.1 Entreprise	1
2.2 Missions	1
3 Bloc 1 – Concevoir et developper une architecture de stockage de donnees	1
3.1 Competences visees	1
3.2 Projets / TP associes	2
3.3 Présentation des projets mobilisés	2
3.4 Justification des compétences du bloc 1	2
3.4.1 Concevoir et développer une base de données relationnelle	2
3.4.2 Concevoir et développer une base de données non relationnelle	2
3.4.3 Concevoir et construire un datalake	3
3.4.4 Créer une API pour rendre les données accessibles	3
3.5 Bilan du bloc 1	3
4 Bloc 2 – Concevoir, developper et deployer une solution de traitement des donnees massives	4
4.1 Competences visees	4
4.2 Projets / TP associes	4
4.3 Analyse attendue	4
5 Bloc 3 – Implementer et optimiser des solutions de stockage et de traitement de donnees sur le cloud	4
5.1 Competences visees	4
5.2 Projets / TP associes	5
5.3 Analyse attendue	5
6 Bloc 4 – Implementer des methodes d'intelligence artificielle	5
6.1 Competences visees	5
6.2 Projets / TP associes	5
6.3 Analyse attendue	5
7 Bloc 5 – Concevoir une strategie de management et de gouvernance de donnees pour transformer les donnees en informations creatrices de valeur	5
7.1 Competences visees	5
7.2 Projets / TP associes	6
7.3 Analyse attendue	6
8 Conclusion	6

Remerciements

Remerciez ici les personnes, équipes et encadrants qui ont accompagné votre formation et la réalisation des projets présentés dans ce rapport.

1 Introduction et note explicative : objectifs

Ce rapport écrit doit être un document structuré et argumenté présentant cinq projets réalisés au cours de la formation. Son objectif est de démontrer l'acquisition des compétences du titre RNCP36739 à travers les projets, TP et travaux menés pendant les deux années de Master 2 Data Engineering & IA.

Le travail attendu est un exercice d'analyse et de synthèse. Il ne s'agit pas seulement de décrire des livrables techniques, mais d'expliquer les besoins, les choix effectués, les difficultés rencontrées, les résultats obtenus et les compétences mobilisées dans chaque bloc.

1.1 Attendus du rapport

- Présenter un fil conducteur cohérent entre les projets et les compétences.
- Argumenter les choix techniques, méthodologiques et organisationnels.
- Montrer la progression, la prise de recul et la capacité d'auto-évaluation.
- S'appuyer sur des preuves concrètes : missions, projets, TP, résultats, captures, extraits de code, schémas ou tableaux de bord.

1.2 Conseil de rédaction

Pour chaque bloc, vous pouvez décrire le contexte du projet, votre rôle, les outils utilisés, les décisions prises, les résultats et la manière dont le projet démontre l'acquisition des compétences attendues.

2 Présentation rapide de l'entreprise et des missions

Présentez ici l'entreprise, son secteur d'activité, son organisation, ainsi que les missions qui vous ont été confiées pendant l'alternance, le stage ou les projets académiques reliés au parcours.

2.1 Entreprise

Décrivez l'entreprise, son contexte métier, ses enjeux data et l'environnement dans lequel vous avez évolué.

2.2 Missions

Pécisez vos responsabilités, les équipes avec lesquelles vous avez travaillé et la nature des projets menés.

3 Bloc 1 – Concevoir et développer une architecture de stockage de données

Cette partie doit montrer comment vous avez conçu et implémenté des solutions de stockage de données adaptées à des cas d'usage variés.

3.1 Compétences visées

- Concevoir et développer une base de données relationnelle en réponse aux besoins d'un client en vue de la mise à disposition de ses données structurées, en utilisant les technologies et les langages de requêtes adaptés aux développements envisagés.
- Concevoir et développer une base de données non-relationnelle en vue de la mise à disposition de données semi-structurées et non structurées pour un traitement analytique ou d'intelligence artificielle, en utilisant les technologies et les langages de requêtes adaptés.

- Concevoir et construire un datalake en choisissant les architectures, les indicateurs de performance et les solutions de stockage appropriées afin d'intégrer des données provenant de systèmes d'information variés.
- Créer une API en utilisant les technologies permettant de rendre les données accessibles et d'augmenter l'efficacité et la praticité des applications et des services.

3.2 Projets / TP associés

- Relational Databases
- NoSQL Databases
- Challenge Datalake 1 Data Integration
- API et Web Services

3.3 Présentation des projets mobilisés

Pour ce bloc, nous nous appuyons principalement sur le projet *Challenge Datalake* réalisé en équipe, dont l'objectif était de construire une plateforme capable de cartographier l'offre et la demande de compétences techniques en Europe. L'idée était d'agréger des données issues de plusieurs sources hétérogènes afin de les centraliser, les normaliser et les rendre exploitables au travers d'une API.

Le scénario métier décrit dans le rapport de rendu s'inscrit dans une logique de veille sur le marché de l'emploi tech : salaires, stacks techniques, niveau d'expérience, popularité des technologies et évolution des besoins. Pour répondre à ce besoin, nous avons construit une architecture de type *Medallion* (Bronze, Silver, Gold), combinant ingestion multi-source, stockage intermédiaire en Parquet, transformation avec PySpark et exposition des données dans une API REST Django.

Le projet s'appuie sur six sources de données principales : Google Trends, StackOverflow Developer Survey, Adzuna Jobs, EuroTech Jobs, GitHub Repositories et Jobcity. Cette diversité de sources nous a obligés à traiter à la fois des données structurées, semi-structurées et issues de scrapping, ce qui rend ce projet particulièrement représentatif des compétences attendues dans le bloc 1.

Pour la sous-compétence NoSQL, nous mobilisons en complément un autre projet, *project_cloud*, dans lequel nous avons utilisé Amazon DynamoDB pour concevoir une base non relationnelle orientée cas d'usage.

3.4 Justification des compétences du bloc 1

3.4.1 Concevoir et développer une base de données relationnelle

Le *Challenge Datalake* démontre clairement cette compétence, car la couche *Silver* puis la couche *Gold* reposent sur MySQL pour structurer et exposer les données nettoyées. Dans ce projet, la base relationnelle ne sert pas uniquement de zone de stockage ; elle joue le rôle de *data warehouse* centralisé, destiné à accueillir des données normalisées provenant de plusieurs sources externes.

Le rapport du projet explique que la couche Bronze collecte les données brutes, que la couche Silver les nettoie et les homogénéise, puis que la couche Gold les unifie pour les rendre exploitables par l'API. Cette logique est confirmée dans le dépôt [julientremont/Jobtech](#), où la configuration Django et les utilitaires SQL montrent l'usage explicite de MySQL. On y retrouve notamment des schémas SQL dédiés, une gestion de connexions centralisée, ainsi qu'une modélisation orientée analyse, avec des tables relationnelles adaptées aux requêtes métier.

Cette partie répond donc à la compétence attendue, car il ne s'agissait pas seulement d'installer une base SQL, mais bien de concevoir une structure relationnelle cohérente avec le besoin client : centraliser des données sur le marché de l'emploi tech, les rendre interrogeables, les relier entre elles et permettre leur exploitation à travers une application. Le choix de MySQL est également pertinent au regard de la nature des données structurées finales, notamment pour les analyses croisées, les filtres, la pagination et les accès via API.

3.4.2 Concevoir et développer une base de données non relationnelle

Cette sous-compétence est justifiée par un autre projet que nous avons réalisé, *project_cloud*. Dans ce dépôt, nous avons conçu une base de données NoSQL avec Amazon DynamoDB afin de stocker des flux de données hétérogènes liés à plusieurs domaines métier, notamment les parkings, le trafic et les départs.

Le projet montre une approche typiquement non relationnelle : les données sont stockées sous forme d'items JSON dénormalisés, enrichis avec des métadonnées communes comme le type de donnée, l'horodatage d'ingestion et les coordonnées. La modélisation n'est pas pensée autour de jointures relationnelles, mais autour des usages applicatifs. Des tables distinctes sont prévues selon les flux métier, et un index secondaire global permet de retrouver efficacement les derniers lots ingérés.

Cette conception répond à la compétence visée, car elle montre que nous avons su adapter le modèle de stockage à des données semi-structurées et à des besoins d'accès rapides, dans une logique orientée exploitation. Le code du projet met en évidence les fonctions d'écriture en lot, de lecture et d'agrégation dans DynamoDB, ainsi que l'exposition de ces données dans une API serverless. Ce projet illustre donc notre capacité à choisir une technologie non relationnelle adaptée lorsque la flexibilité du schéma, la dénormalisation et la performance de lecture sont prioritaires.

3.4.3 Concevoir et construire un datalake

Le *Challenge Datalake* est la partie la plus représentative de cette compétence. L'architecture mise en place repose sur une logique *Bronze / Silver / Gold*, explicitement décrite dans le rapport du projet. La couche Bronze sert à collecter les données brutes depuis différentes sources externes et à les stocker localement au format Parquet. La couche Silver applique les traitements de nettoyage, de normalisation et d'enrichissement. Enfin, la couche Gold consolide les données dans un entrepôt exploitable par l'API et par les analyses.

Le choix de cette architecture est pertinent car il permet de séparer clairement les responsabilités : ingestion brute, préparation de la donnée et exposition des données consolidées. Cette organisation facilite la maintenance, la traçabilité et la reprise des traitements. Elle répond aussi à la diversité des systèmes sources : API publiques, fichiers CSV, enquêtes annuelles, scraping web et données issues de plateformes open source.

Le rapport de rendu détaille plusieurs flux : Google Trends avec collecte historique et quotidienne, StackOverflow Survey avec import de fichiers annuels, Adzuna avec appels API mensuels, EuroTech Jobs et Jobicy via scraping, ainsi que GitHub Repositories via API publique. Cette variété de formats et de rythmes d'ingestion illustre bien la capacité à intégrer des données structurées, semi-structurées et non structurées dans une architecture unique. Le stockage en Parquet et le traitement avec PySpark montrent en outre une démarche orientée performance et scalabilité, notamment grâce au partitionnement temporel et à la standardisation progressive des colonnes.

Nous pouvons donc justifier cette compétence en montrant que le projet ne se limite pas à une simple agrégation de fichiers : il s'agit bien d'un datalake conçu pour absorber plusieurs sources, conserver la donnée brute, produire une donnée fiabilisée et la rendre exploitable dans une couche analytique. C'est précisément l'objectif attendu dans ce bloc.

3.4.4 Créer une API pour rendre les données accessibles

La dernière sous-compétence du bloc est également couverte par le *Challenge Datalake* grâce à l'API REST développée avec Django et Django REST Framework. Le rapport du projet consacre une partie complète à cette API et à son rôle de vitrine de données. L'objectif n'était pas seulement d'entreposer les données, mais de les rendre accessibles de manière claire, documentée et sécurisée.

L'API est organisée par source de données, avec des routes dédiées pour Google Trends, StackOverflow Survey, Adzuna, GitHub, EuroTech Jobs et Jobicy, ainsi que des endpoints d'analyse transverses pour la couche Gold. Le dépôt montre également la présence d'une documentation Swagger / OpenAPI, d'une authentification par session et JWT, d'un système de permissions, ainsi que de fonctionnalités de filtrage, tri et pagination. Ces éléments sont importants, car ils traduisent une conception orientée usage et non une simple exposition brute des tables.

Cette API justifie pleinement la compétence attendue : elle permet à des clients ou à d'autres services d'interroger les données selon leurs besoins, de récupérer des résumés, des séries temporelles ou des analyses métier, tout en conservant un cadre technique robuste. Elle améliore donc concrètement l'accessibilité et la praticité des données, ce qui correspond exactement à l'objectif de la sous-partie *API et Web Services*.

3.5 Bilan du bloc 1

Au travers de ces deux projets, nous pouvons justifier l'ensemble des sous-compétences du bloc 1. Le *Challenge Datalake* démontre notre capacité à concevoir une architecture de stockage complète, à

centraliser plusieurs flux de données, à structurer une base relationnelle et à exposer les données via une API robuste. Le projet *project_cloud* complète cette démonstration sur la partie NoSQL, avec un cas concret d'usage de DynamoDB pour des données semi-structurées. Dans l'ensemble, ces réalisations montrent notre capacité à choisir les bons modèles de stockage selon les usages, à organiser les flux de données de bout en bout et à mettre les données à disposition de manière exploitable.

4 Bloc 2 – Concevoir, développer et deployer une solution de traitement des données massives

Cette partie doit montrer votre capacité à concevoir, industrialiser et optimiser des pipelines de traitement de données à grande échelle.

4.1 Competences visees

- Concevoir, en s'appuyant sur une veille technologique, une architecture distribuée répondant au besoin du client pour traiter les données massives en entreprise en utilisant les technologies de traitement adaptées.
- Implémenter un système distribué en utilisant des technologies de streaming identifiées à partir d'une veille pour traiter des données sur une période précise ou en temps quasi réel.
- Transformer les données provenant de différentes sources en prenant en compte leur variété pour faire de l'analytique à l'échelle.
- Optimiser la performance des pipelines en utilisant les techniques d'intégration et de mise en scène adéquates pour le traitement des données massives.
- Automatiser la création, les tests, l'intégration et le déploiement des pipelines de données en utilisant les technologies de containerisation et d'ordonnancement pertinentes.

4.2 Projets / TP associes

- Data Integration
- Big Data Frameworks
- Functional Data Programming
- DevOps & MLOps

4.3 Analyse attendue

Mettez en avant la conception des pipelines, le traitement distribué, les choix de performance, l'automatisation et la manière dont vous avez déployé ou industrialisé les traitements.

5 Bloc 3 – Implémenter et optimiser des solutions de stockage et de traitement de données sur le cloud

Cette partie doit démontrer votre maîtrise des services cloud appliqués au stockage, au traitement, à la sécurité et à l'optimisation des coûts.

5.1 Competences visees

- Mettre en œuvre des solutions de stockage de données dans le cloud pour permettre aux entreprises d'explorer leurs données en implémentant des techniques et stratégies adaptées à leur utilisation.
- Concevoir et développer des pipelines et des solutions de traitement de données dans le cloud en chargeant les données, en les transformant et en les mettant à disposition des utilisateurs.
- Mettre en place une politique de sécurité des données dans le cloud en développant une stratégie de chiffrement et de gestion des identités et des accès, dans le respect des règlements en vigueur.
- Optimiser les solutions de stockage et de traitement des données dans le cloud en définissant des indicateurs de performance pour assurer la disponibilité des services et optimiser les coûts.

5.2 Projets / TP associes

- Projet Cloud
- Securite des donnees

5.3 Analyse attendue

Detaillez les services cloud mobilises, les mecanismes de securisation, les flux de donnees, la supervision, les arbitrages techniques et les optimisations mises en place.

6 Bloc 4 – Implementer des methodes d'intelligence artificielle pour modeliser et predire de nouveaux comportements et usages

Cette partie doit montrer comment vous avez exploite les donnees pour produire de l'analyse, du reporting et des modeles predictifs utiles au metier.

6.1 Competences visees

- Extraire des donnees en provenance de systemes d'information varies pour les exploiter et les analyser en utilisant les outils professionnels courants.
- Preparer les donnees en les transformant et en les nettoyant pour faire l'analyse et le reporting selon les besoins des differents metiers.
- Elaborer une communication infographique visuelle en construisant des tableaux de bord interactifs afin de communiquer les resultats d'analyse et d'assurer l'extraction de connaissances en temps reel.
- Developper un modele predictif pour identifier de nouveaux comportements et usages en implementant des algorithmes d'apprentissage automatique supervises.
- Evaluer la performance d'un modele de machine learning en analysant ses resultats et en les comparant avec d'autres modeles afin d'implementer la solution la plus convenable a un cas d'usage.

6.2 Projets / TP associes

- Projet Data Science
- Hackathon

6.3 Analyse attendue

Expliquez la preparation des donnees, les analyses produites, les modeles testes, les metriques utilisees, les resultats obtenus et leur valeur pour l'usage cible.

7 Bloc 5 – Concevoir une strategie de management et de gouvernance de donnees pour transformer les donnees en informations creatrices de valeur

Cette partie doit montrer votre capacite a relier les enjeux techniques aux enjeux organisationnels, reglementaires, qualitatifs et strategiques de la data.

7.1 Competences visees

- Definir une gouvernance de donnees en mettant en place les politiques et les standards afin d'etablir les roles, les responsabilites et la propriete des donnees.
- Mettre en place les bonnes pratiques de gestion de donnees en appliquant les regulations en vigueur pour proteger les donnees et respecter la vie privee dans une logique de transparence.
- S'assurer que la qualite de la donnee permet d'atteindre les objectifs business en faisant un audit de qualite et en proposant des plans de prevention et de remediation en cas de non-qualite.

- Identifier l'approche strategique pour faire de la donnee un actif central ancre dans la culture de l'entreprise et integrer cette approche dans un plan de communication diffuse aux personnes concernees.
- Elaborer une strategie de securite afin de proteger les donnees en utilisant les technologies adequates et en mettant en place une politique d'accès aux donnees.

7.2 Projets / TP associes

- Data Management & gouvernance

7.3 Analyse attendue

Mettez en avant les enjeux de gouvernance, de qualite, de securite, de conformite et de communication autour de la donnee, en montrant comment vos travaux transforment la data en valeur pour l'organisation.

8 Conclusion

Concluez en rappelant le fil conducteur du rapport, la progression observee sur les deux annees de formation, les competences acquises et votre capacite a argumenter, justifier vos choix et prendre du recul sur vos realisations.

Vous pouvez terminer cette conclusion par une ouverture vers la soutenance, qui devra s'appuyer sur un support synthetique et pertinent et mettre en valeur votre e-portfolio de competences.